




Métricas de Evaluación para Agentes de IA


Un marco integral para medir Eficacia, Eficiencia y Razonamiento.

AI Engineering Series

Más allá del 'Accuracy'

Por qué los Agentes requieren una evaluación multidimensional.

ML Tradicional



Limitaciones:

El accuracy simple ignora el costo y el tiempo.


Realidad:

Un agente correcto puede ser inviable económicamente.

3 Dimensiones:


Eficacia, Eficiencia, Lógica.

Agentes de IA



Definiendo el Éxito

Task Completion Rate y Criterios




Task Completion Rate: Porcentaje de tareas completadas exitosamente sobre el total de intentos.

Success Criteria: El éxito es binario pero compuesto. No basta con la respuesta correcta.

Restricciones: Cumplimiento estricto de formato y tono.

El Sistema de Evaluación

Ponderación y el “LLM Judge”.



Evaluación Multi-criterio

Combinación ponderada de métricas según impacto de negocio.

LLM Judge

Uso de modelos superiores para evaluar cualidades humanas (empatía, coherencia).

Ground Truth

Comparación directa contra “Golden Datasets” cuando existen.

En la Práctica: Scorecard

Ejemplo para Agente de Customer Support.

Agent Evaluation: Ticket #402			
Criterio	Pregunta de Control	Peso	Score
Precisión	¿La solución técnica es correcta?	50%	10/10
Empatía	¿El tono es adecuado para un cliente frustrado?	30%	8/10
Formato	¿Respondió en JSON válido?	20%	10/10
Weighted Score: 9.4/10			

Personalización: Los pesos se ajustan al caso de uso. En generación de código, la sintaxis tendría peso 100%.

El Triángulo de la Eficiencia

Balanceando Recursos y Calidad.



El Trade-off: Un agente funcionalmente perfecto es inútil si quiebra el presupuesto o hace esperar al usuario.

Midiendo el Consumo

Tokens y Costo por Éxito.

Costo por Tarea Exitosa

\$0.05 / tarea

Prompt Verboso
+
Re-generación

Standard

\$0.01 / tarea

Prompt Conciso
+ Caching

Optimized

Metric Focus: Cost per Success

Costo Total / Tareas Exitosas


Justifica la inversión en modelos más caros si estos reducen la tasa de fallo y reintentos.

Estrategias:

- Caching: Costo cero en tareas repetitivas.
- Concisión: Reducir tokens/step.

Analizando la Velocidad

La Trampa del Promedio y el P95.



Streaming: Reduce la latencia percibida.




Timeouts: Límites duros para evitar colgados.



Small Models: Para tareas de baja complejidad.


Estrategias de Optimización

Cómo resolver cuellos de botella.



Router de Modelos

Desviar tareas simples a modelos pequeños y rápidas; tareas complejas a modelos grandes.



Caching Semántico

Almacenar respuestas frecuentes. Evitar computación redundante.



Batching

Agrupar solicitudes paralelas para reducir el overhead de red.




Retry Logic

Reintentos automáticos inteligentes ante fallos de API.

Calidad de Razonamiento

Abriendo la “Caja Negra”.



Chain of Thought (CoT):


La secuencia de pasos intermedios que el agente genera antes de la respuesta final.

¿Por qué importa?

Evitar la “alucinación correcta” (respuesta bien, lógica mal).
La robustez requiere fundamentación (Grounding).

Anatomía del Razonamiento

Desglose de una cadena de pensamiento válida.



Anti-Patrones Comunes

- Saltos de lógica sin evidencia.
- Razonamiento circular.
- Ignorar restricciones negativas.

Evaluación Automatizada


Validando la lógica a escala.



Entrenamiento: Las cadenas fallidas se convierten en “Negative Examples’ para mejorar el prompt (Few-shot prompting).

Dashboard de Métricas


Visibilidad en Tiempo Real.



Visualización unificada para correlacionar costo, velocidad y calidad.

Mejora Continua: A/B Testing

Comparación de versiones v1 vs v2.



Significancia Estadística: Validar que las mejoras no sean ruido aleatorio antes del despliegue.

Resumen: Hoja de Ruta

Checklist para Agentes Robustos.

Pilar	Acción Clave	Métrica Principal
1. Eficacia	Definir Success Criteria & LLM Judge	Task Completion Rate
2. Eficiencia	Monitorear P95 & Caching	Cost per Success
3. Razonamiento	Extraer & Validar Chain of Thought	Coherence Score

“Lo que no se mide, no se puede mejorar.
La viabilidad depende del equilibrio.”