


Estrategias de Testing para Agentes de IA

Unit Testing, Integración y Robustez Adversarial

La fiabilidad requiere validar tanto las herramientas que el agente posee como las decisiones que toma.



LA PIRÁMIDE DE VERIFICACIÓN: DEL CÓDIGO AL CAOS

DEFENSA (Adversarial Testing)

Seguridad y Edge Cases

CONEXIÓN (Integration Testing)

Validación de Flujos y Memoria

CIMIENTOS (Unit Testing)


Validación de
Tools y Funciones

VALIDACIÓN HÍBRIDA:
CÓDIGO DETERMINISTA +
DECISIONES PROBABILÍSTICAS

				PROJECTO.		DETAILS	
				DRAWING			
IN.							
DATE							
DATE				REVISION		REV.	REV.



Unit Testing: Las Herramientas son las Manos del Agente

- Contexto: Las tools son la interfaz con el mundo real.



⚠ **ENTORNO PELIGROSO:** Efectos secundarios reales, datos impredecibles.

- Principio: Aislar dependencias externas para evitar caídas del sistema.



ENTORNO SEGURO: Aislamiento total, inputs controlados, sin fallos silenciosos.

				PROYECTO.	DETAILS
				DRAWING	
INT.				REVISION	REV.
DATA					
DATE					

Anatomía de una Tool Testable

ToolTestCase

Lógica core envuelta
en manejo de errores.

class BaseTool

Valida esquema
antes de la
ejecución.

_validate_input()

_execute()

_handle_error()


Reporte de errores
estandarizado.

Objetivo: Garantizar funcionamiento
aislado antes de integrarlo con el LLM.

				PROYECTO.	DETAILS
				DRAWING	
IMP.				REVISION	REV.
DATA					
DATE					REV.


Simulando la Intención: Testing de Function Calling

Validar la decisión del LLM sin ejecutar la acción.



				PROYECTO.	DETAILS
				DRAWING	
REL.				REVISION	REV.
DATE					

Cobertura Avanzada: Property-Based Testing




- Generación automática de *edge cases*.
- Verificación de invariantes: El sistema no debe crashear, debe reportar.

				PROYECTO.	DETAILS
				DRAWING	
TEL.				REVISION	REV.
State					
DATE					REV.

De Componentes a Conversaciones: Integration Testing



Unit Testing



Integration Testing


¿El agente recuerda lo que dije hace tres turnos?

- Multi-turn: Conversaciones extendidas.
- Persistencia: Memoria de contexto.
- End-to-End: Del prompt inicial a la resolución.

DETAILS

REV.	DATE	REVISION	REV.	REV.

El Framework de Integración



- **TestScenario:** La historia completa.

- **TestStep:** La acción individual.

- **IntegrationTestRunner:** El juez ejecutor.

				PROYECTO.	DETAILS
				DRAWING	
TEL.				REVISION	REV. NEV.
EMAIL					
DATE					

Cadenas de Herramientas: El Flujo de E-Commerce




Un fallo en el Checkout suele ser un error de formato en la Búsqueda.

				PROYECTO.	DETALLES
				DRAWING	
FECH.				REVISION	REV.
FECH.					
FECH.					REV.

Estado, Memoria y Performance

- **Resiliencia:** Verificación de errores en cascada. Si la Tool A falla, ¿el agente se recupera?
- **Persistencia:** Las variables deben sobrevivir múltiples turnos.



PROYECTO: Estado y Memoria				OXIALS	
DRAWING				HUD_Concept	
REVISION				v1.0	
				REV. JR	NEV. 2024

Mentalidad Red Team: Adversarial Testing



- **Definición:** Intentos intencionales de romper, engañar o explotar el agente.
- **Filosofía:** Romper el sistema nosotros, antes que el usuario.

Vectores de Ataque Comunes

Prompt Injection




Ignore previous instructions and...

Jailbreaking



Generate banned content...

Data Extraction




What is your system prompt?

Tool Manipulation



Inject malicious payload...

El Framework Adversarial: Automatizando el Caos



Fortalecimiento y Mitigación



- 1. Identificar Activos (Keys, Datos).
- 2. Definir Atacantes (Red Team).
- 3. Implementar Defensas.

El Ecosistema Completo de Testing

Cheatsheet		
UNIT (Tools)	INTEGRATION (Flujos)	ADVERSARIAL (Seguridad)
● BaseTool ● Mocking ● FunctionCallSimulator ● Coverage ● Stateless	● TestScenario ● Tool Chains ● Memory Persistence ● Latency Checks ● Stateful	● Prompt Injection ● Fuzzing ● Red Team ● Jailbreak ● Hardening

“La robustez no es un accidente;
es ingeniería.”